

DocTutor

Biến mọi tài liệu thành gia sư riêng

Chatbot hỏi đáp tài liệu học tập sử dụng RAG

Tài liệu tổng quan dự án

(Tên dự án là tạm — nhóm có thể thay đổi)

Mục lục

1. Tổng quan dự án

DocTutor là một chatbot hỏi đáp tài liệu học tập. Người dùng tải lên một file PDF — giáo trình, slide bài giảng, bài nghiên cứu — và đặt câu hỏi bằng ngôn ngữ tự nhiên. Hệ thống tìm những đoạn liên quan trong tài liệu rồi trả lời chính xác dựa trên nội dung đó, thay vì bắt người học đọc hết hàng chục trang.

Điểm cốt lõi là toàn bộ mô hình AI chạy cục bộ trên máy thông qua Ollama, không phụ thuộc dịch vụ trả phí hay kết nối internet liên tục. Điều này giúp dự án dễ triển khai, bảo mật dữ liệu tài liệu, và phù hợp với bối cảnh học tập tại Việt Nam.

2. Vấn đề giải quyết

Các mô hình ngôn ngữ lớn (LLM) như ChatGPT rất mạnh, nhưng chỉ biết những gì đã được huấn luyện sẵn. Chúng không thể trả lời chính xác về một tài liệu riêng mà người dùng vừa đưa vào, và có xu hướng “bịa” thông tin khi không biết câu trả lời.

Với người học, điều này tạo ra một khoảng trống: họ có tài liệu trong tay nhưng không có cách hỏi đáp nhanh, đáng tin cậy trên chính tài liệu đó. DocTutor lấp khoảng trống này bằng kỹ thuật RAG.

3. Giải pháp: Kiến trúc RAG

RAG (Retrieval Augmented Generation) hoạt động theo nguyên tắc đơn giản: trước khi để LLM trả lời, hệ thống tìm những đoạn văn bản liên quan trong tài liệu rồi đưa kèm câu hỏi cho mô hình. Nhờ vậy, câu trả lời bám sát nội dung thật và hạn chế bịa đặt.

Luồng xử lý gồm 5 bước:

1. Chunking — chia PDF thành các đoạn ngắn để embedding và tìm kiếm chính xác hơn, đồng thời không vượt quá giới hạn ngữ cảnh của LLM.
2. Embedding — chuyển mỗi đoạn thành một vector số để máy so sánh được mức độ tương đồng về ý nghĩa.
3. Lưu Vector Database — lưu toàn bộ vector vào ChromaDB để tìm kiếm nhanh.
4. Retrieval — khi có câu hỏi, tìm các đoạn gần nhất về ngữ nghĩa với câu hỏi.
5. Generation — ghép câu hỏi và các đoạn tìm được thành prompt, đưa cho LLM sinh câu trả lời.

So với việc dùng framework lớn như LangChain, dự án triển khai RAG bằng Python thuần với rất ít thư viện. Cách này giúp cả nhóm hiểu rõ từng bước, dễ kiểm soát và dễ mở rộng tính năng về sau.

4. Công nghệ sử dụng

Hệ thống được xây dựng gọn nhẹ, ưu tiên các thành phần mã nguồn mở chạy cục bộ:

Thành phần	Công nghệ	Vai trò
Giao diện	Streamlit	Web UI: upload PDF, khung chat, hiển thị lịch sử
Đọc tài liệu	pypdf	Trích xuất văn bản từ file PDF
Vector Database	ChromaDB	Lưu và tìm kiếm vector theo ngữ nghĩa
Embedding	BGE-M3 (Ollama)	Chuyển văn bản thành vector 1024 chiều, hỗ trợ tiếng Việt
Mô hình ngôn ngữ	Qwen2.5 / Gemma2 (Ollama)	Sinh câu trả lời tiếng Việt từ ngữ cảnh
Chạy mô hình	Ollama	Chạy LLM cục bộ, không cần GPU đắt tiền hay internet

Lưu ý kỹ thuật: bản gốc của tài liệu tham khảo dùng mô hình Vicuna-7B (tiếng Việt ở mức cơ bản). Vì tài liệu học tập của nhóm hướng tới tiếng Việt, dự án ưu tiên các mô hình xử lý tiếng Việt tốt hơn như Qwen2.5 hoặc Gemma2 — chỉ cần đổi cấu hình, không phải sửa kiến trúc.

5. Tính năng

Ngoài chức năng hỏi đáp cốt lõi, dự án phát triển thêm các tính năng tạo khác biệt cho bối cảnh học tập:

Tính năng	Mô tả	Trạng thái
Hỏi đáp tài liệu (RAG)	Upload PDF, đặt câu hỏi, nhận câu trả lời dựa trên nội dung tài liệu	Lỗi
Trích dẫn nguồn	Câu trả lời kèm số trang để người dùng kiểm chứng	Ưu tiên cao
Tạo Quiz / Flashcard	Tự sinh câu hỏi trắc nghiệm và thẻ ghi nhớ từ tài liệu	Điểm nhấn
Tóm tắt theo chương	Tóm tắt nhanh toàn bộ hoặc từng phần tài liệu	Mở rộng
Ghi nhớ hội thoại	Hỏi nối tiếp dựa trên ngữ cảnh các câu trước	UX
Hỏi nhiều tài liệu	Upload và truy vấn tổng hợp trên nhiều file cùng lúc	Mở rộng
Hybrid Search + Rerank	Kết hợp từ khóa (BM25) và ngữ nghĩa, xếp lại kết quả để tăng độ chính xác	Nâng cao

Hai tính năng được ưu tiên vì tác động trực tiếp tới giá trị sản phẩm khi trình bày: trích dẫn nguồn (tạo độ tin cậy — người dùng kiểm chứng được câu trả lời ở trang nào) và tạo quiz/flashcard (đúng nhu cầu của người học và gây ấn tượng mạnh).

6. Điểm khác biệt

- Chạy hoàn toàn cục bộ — bảo mật tài liệu, không tốn chi phí API, không cần GPU đắt tiền.

- Tối ưu cho tiếng Việt — từ mô hình embedding đa ngôn ngữ tới LLM xử lý tiếng Việt tốt.
- Có trích dẫn nguồn — mỗi câu trả lời truy ra được trang trong tài liệu, tăng độ tin cậy cho mục đích học tập.
- Vượt khỏi hỏi đáp đơn thuần — tạo quiz, flashcard và tóm tắt, biến tài liệu tĩnh thành công cụ học chủ động.
- Kiến trúc minh bạch, dễ mở rộng — code Python thuần, dễ bảo trì và phát triển tiếp.

7. Lộ trình phát triển

Dự án triển khai theo từng giai đoạn, đảm bảo phần nền móng vững trước khi mở rộng tính năng:

Giai đoạn	Nội dung	Kết quả
GĐ 0 – Nền móng	Tách file (rag_core + app), giữ metadata trang, collection chung cho multi-file, lưu trữ lâu dài, đổi LLM tiếng Việt	Code base vững, sẵn sàng mở rộng
GĐ 1 – UX cốt lõi	Ghi nhớ hội thoại, stream câu trả lời, chọn model trong giao diện	Trải nghiệm chat mượt mà
GĐ 2 – Khác biệt	Trích dẫn nguồn, tạo quiz/flashcard, tóm tắt, hỏi nhiều tài liệu	Tính năng gây ấn tượng khi thi
GĐ 3 – Nâng cao	Hybrid search, reranking, OCR cho PDF scan	Tăng độ chính xác, mở rộng đầu vào

Nguyên tắc quan trọng: hoàn thành Giai đoạn 0 trước khi chia việc song song. Việc giữ metadata trang và tổ chức collection chung phải quyết định ngay từ đầu, vì các tính năng như trích dẫn nguồn và hỏi nhiều tài liệu đều phụ thuộc vào nền tảng này.

8. Kết luận

DocTutor giải quyết một nhu cầu thực tế và phổ biến của người học: hỏi đáp nhanh, đáng tin cậy trên tài liệu của chính mình. Với kiến trúc RAG gọn nhẹ chạy cục bộ, tối ưu cho tiếng Việt, cùng các tính năng học tập chủ động như quiz và trích dẫn nguồn, dự án vừa khả thi về kỹ thuật vừa có giá trị sản phẩm rõ ràng khi trình bày.